

AI 客服 Demo 需求拆解 v0.1

2026-07-24 · 供团队讨论与排期，参考对标：Cresta (cresta.com)

需求按 user story 格式编写（作为〈角色〉，我可以〈做什么〉，以便〈获得什么价值〉），可直接录入 DevOps/Jira

一、Demo 定位

- 本 demo 是《企业全面AI化解决方案说明书》板块（三）"售后服务与客服"的可运行样例，服务于诊断阶段的现场演示，目的是让企业直观看到 AI 客服的形态，不是完整产品
- 面向各类企业，不预设行业（与说明书 v0.5 定位一致）。demo 做成"知识库可更换"的通用件，演示时按企业类型换知识库和演示剧本：
 - B2B 高价值场景（制造/外贸等）：主打询盘不漏、行业术语级专业应答、多语言（外贸场景选配）
 - B2C 高触点场景（教育/房产/汽车/零售金融等）：主打大量重复咨询的 AI 自答率、7×24 响应、应答口径一致可控
 - 共同卖点：应答知识沉淀为公司资产（对应 AI Native"知识即服务"）
- 与说明书客服板块功能要点的对应：常见问题AI应答 = R2，服务质检 = R3/R6，主动回访提醒 = R5，工单自动分类 = R11
- 边界表述：不承诺无人化——关键决策、承诺性表述、客户关系由人把关，AI 承担过程性工作。因此"转人工"在 demo 中是显性卖点，不是能力缺陷

二、来自 Cresta 的设计参考（要点）

设计点	Cresta 做法	我们 demo 的取舍
模型架构	平台 20+ 大小模型按任务分工编排（对话主体用前沿基座模型，摘要/检测用微调小模型；自研模型路线已放弃）	demo 用 3 个模型讲同一个故事：主对话 + 红线检查 + 摘要，不自研、不堆模型
知识问答	回答强制带出处；证据不足时拒答而不编造	完整复刻，这是可信度的根基
安全红线	与主模型并行的监督分类器，可拦截违规输出	简化复刻：并行红线检查 + 拦截日志
转人工	交接时给人工完整摘要包，"human agents start informed"	完整复刻
核心指标	containment（AI 自答率）、CSAT、AHT	demo 看板取 AI 自答率 + 转人工率 + 知识缺口
知识反哺	从会话中发现知识库答不上的问题，反向补知识	做成看板上的"知识缺口清单"
语音	级联 ASR→LLM→TTS，延迟目标 <800ms，语义打断检测	列为 P1，demo 放宽到 <1.5s、基础打断

技术细节可查 Cresta 工程博客（做 P1 语音时重点读第一篇）：

- 语音延迟工程：<https://cresta.com/blog/engineering-for-real-time-voice-agent-latency>
- 知识工程（RAG 方法论）：<https://cresta.com/blog/ai-ready-knowledge-for-contact-centers-closing-the-gap-between-kbs-and-ai>
- Guardrail 架构：<https://cresta.com/blog/crestas-three-strategic-pillars-of-ai-agent-defense-for-enterprise-security-and-compliance>

三、需求清单

优先级：P0 = 文字客服闭环（最小可演示单元）；P1 = 语音版；P2 = 演示加分项。

P0 · 文字客服闭环

R1 知识摄入

- 作为企业管理员，我可以上传产品手册/FAQ（PDF、Word）或输入官网网址，以便 AI 客服在几分钟内学会本公司的产品知识
- 验收：输入一个企业官网 URL + 上传一份产品 PDF 后，5 分钟内可开始问答

R2 对话应答（对客户）

- 作为客户，我在网页聊天窗用中文或英文提问，可以得到基于企业知识库的准确回答，且每个回答附出处（手册章节/网页链接），以便我确认信息可靠
- 作为客户，当我的问题超出知识库范围时，AI 明确告知无法回答并转人工，而不是编造答案
- 验收：知识内问题回答带出处；知识外问题 100% 拒答并转人工；中文必选，英文/多语言应答作为外贸场景选配（演示外贸类企业时启用）

R3 红线检查

- 作为企业管理员，我可以设置 AI 不允许说的话（如：不承诺价格、不承诺交期、不评价竞品），以便 AI 对外应答始终可控
- 验收：现场诱导 AI 承诺交期，输出被拦截并转人工；后台可查看拦截日志

R4 转人工交接

- 作为人工客服，我接管会话时能立即看到会话摘要、客户信息卡片、AI 建议的下一步动作，以便不用从头问一遍
- 验收：转接后人工界面 3 秒内出现完整摘要包
- 待定：客户信息卡片的字段清单（建议 Marvis 按过往 implementation 经验定义）

R5 会话总结与跟进建议

- 作为客服/销售主管，每通会话结束后我可以看到自动生成的会话总结、客户意向标签、下次跟进策略建议和个性化话术，以便团队跟进不断档
- 验收：对应功能模块清单中"会话自动总结、下一次跟进策略推荐、个性化推荐话术"三项逐条可演示

R6 管理看板

- 作为企业负责人，我可以看到会话总量、AI 自答率、转人工率，以及"客户常问但知识库答不上的问题清单"，以便判断 AI 客服的实际效果和知识建设方向
- 验收：看板含知识缺口清单，且可从缺口一键补录知识（补录后再问即可命中）

P1 · 语音版

R7 语音对话

- 作为客户，我可以用语音与 AI 客服对话（网页端即可，不必接电话线），响应停顿不超过 1.5 秒，我插话时 AI 会停下来听
- 验收：端到端延迟 <1.5s；插话后 AI 停止播报并处理新输入
- 技术参考（供选型，不指定）：级联 ASR→LLM→TTS；编排框架可评估 Pipecat / LiveKit Agents；ASR/TTS 中文可评估讯飞/火山/阿里云，英文可评估 Deepgram/ElevenLabs
- 排期建议：P0 验证通过后再启动；若首个演示对象明确要看语音，则提前

P2 · 演示加分项

R8 历史会话挖掘

- 作为企业，我可以导入一批历史客服记录（邮件/聊天导出），系统提炼高频问题 TOP10 与最佳答复，一键生成知识条目，以便冷启动知识库并发现自动化机会

R9 仿真测试

- 作为交付团队，我可以在上线前用模拟客户（不耐烦的、跳话题的、诱导 AI 犯错的）自动测试 AI 客服并生成测试报告，以便向企业证明质量有保障
- 说明：demo 阶段可用固定脚本演示

R10 坐席辅助模式

- 作为人工客服，我处理会话时 AI 在侧边实时推荐答案和知识，由我决定是否采用，以便对暂不接受 AI 直接面客的企业提供

渐进式方案

R11 工单自动分类

- 作为客服主管，进线会话可以自动按类型（咨询/投诉/售后/其他）和紧急度打标并生成工单记录，以便分派处理和统计
- 说明：对应说明书客服板块"工单自动分类"；demo 阶段做到自动打标 + 工单列表即可，不对接真实工单系统

四、演示动线（5 分钟）

1. 现场输入目标企业官网网址 + 上传一份产品 PDF → "AI 客服 5 分钟上岗" (R1)
2. 以客户身份中文提问 → 带出处回答 (R2)；后续按企业类型走不同剧本——外贸企业：切英文提问 → 行业术语专业应答；B2C 企业：连续问多个高频重复问题 → 展示 AI 自答率与口径一致性
3. 诱导 AI 承诺交期 → 拦截并转人工 → 人工侧收到摘要包 (R3、R4)
4. 打开管理看板 → AI 自答率 + 知识缺口清单 (R6)
5. （若 P1 已就绪）语音对话收尾 (R7)